

AgroSearch — Relatório Técnico

Laboratório Prático 04 · Tendências em Ciência da Computação · Prof. Me. Ricardo Roberto de Lima.
Equipe: Victor (entrega individual).

1. Objetivo

Protótipo de motor de busca textual para os manuais técnicos da AgroTech Solutions: o técnico digita uma consulta e recebe os trechos mais relevantes, ranqueados por TF-IDF. Tudo em um único arquivo Streamlit (*agrosearch_app.py*), sem scikit-learn nem TfidfVectorizer: índice invertido, TF-IDF e stemmer foram implementados do zero com a biblioteca padrão.

2. Arquitetura

Fase	Implementação
1. Pré-processamento	tokenização (<code>\w+</code>), normalização (minúsculas e remoção de acentos via Unicode NFD), remoção de stopwords (lista própria em português) e stemming (stemmer próprio por sufixos). Checkboxes ligam/desligam stopwords e stemming; o vocabulário exibido muda na hora (47 termos sem nenhum filtro, 34 com os dois ligados).
2. Índice invertido	dicionário termo → lista ordenada de IDs, construído a partir dos tokens limpos e exibido com <code>st.json</code> (34 termos; ex.: <code>soj</code> → <code>[1, 2, 4]</code>).
3. Busca TF-IDF	a consulta passa pelo mesmo pipeline; para cada documento calcula TF, IDF e TF-IDF de cada termo e soma (TF-IDF acumulado). A tabela é ordenada do maior para o menor score e o vencedor recebe o troféu na coluna de destaque e uma mensagem verde.

3. Fórmulas e decisões

- **TF(t, d)** = ocorrências de t em d / total de termos de d (slide 18 da Aula 3).
- **IDF(t)** = $\log_{10}(N / df(t))$, com $N = 5$; termo ausente da coleção vale 0. A base 10 reproduz os números dos slides 19 e 20 ($\log(3/2) \approx 0,176$).
- **TF-IDF acumulado** = soma do TF-IDF dos termos distintos da consulta no documento.
- **Stemmer:** remove o sufixo mais longo de uma lista (ex.: -ação, -mento, -idade, -as, -os, -s) desde que sobre um radical de pelo menos 3 letras; "lagartas" e "Lagartas" viram lagart, "irrigação" vira irrig.

4. Exemplo: consulta "irrigação da soja"

Termos após o pipeline: irrig, soj ("da" é stopwords). $IDF(irrig) = \log_{10}(5/2) = 0.3979$, $IDF(soj) = \log_{10}(5/3) = 0.2218$.

Posição	Documento	TF-IDF(irrig)	TF-IDF(soj)	TF-IDF acumulado
1	Doc 1	0.0497	0.0277	0.0775
2	Doc 5	0.0568	0.0000	0.0568
3	Doc 2	0.0000	0.0277	0.0277
4	Doc 4	0.0000	0.0277	0.0277
5	Doc 3	0.0000	0.0000	0.0000

Vencedor: **Doc 1**, único que tem os dois termos e o mais curto entre os que citam irrigação.

5. Importação de arquivos

A base pode ser ampliada ou substituída pela barra lateral com manuais em .txt, .md, .csv ou .pdf. Cada parágrafo vira um documento: num .txt sem linhas em branco, cada linha; no CSV, a coluna "texto"; no PDF, os parágrafos de cada página. Repetições e trechos com menos de 40 caracteres são ignorados, e cada documento guarda a origem (arquivo e página ou linha). A leitura usa *csv*, *io* e *pypdf* só para extrair o texto: o índice invertido e o TF-IDF continuam calculados do zero sobre a nova base, com N igual ao número de documentos.

6. Divisão de tarefas

Tarefa	Responsável
Pipeline de pré-processamento e stemmer	Victor
Índice invertido e TF-IDF	Victor
Interface Streamlit	Victor
Importação de arquivos e relatório	Victor